

# 高等数理统计复习

## 第一章

- 样本空间及相关概念
  - **随机试验**：受偶然性因素影响，导致结果不正确的试验；
  - **个体**：试验的结果；
  - **样本空间**：所有个体组成的集合；
  - **样本**：多次（ $n$ 次）试验的结果构成的一个向量；
    - 样本有两重性，在抽样之前是随机的，抽样之后表现为一组数。
  - **简单随机样本**：试验在相同的条件下独立进行得到的样本；
  - **样本量**：试验重复的次数 $n$ ；
  - **事件**：样本空间的子集；
  - **总体分布**：称随机抽样得到的一个样本点的分布为总体分布（简称为总体），这是感兴趣的对象。
  - **样本分布**：样本的概率分布称为样本分布；简单随机样本的分布由总体分布及样本量确定。

- 测度与积分

- **定义1.1**：设全集为 $\mathcal{X}$ ， $\mathcal{A}$ 为其一些子集构成的集合，称为 $\sigma$ -域，若：
  1.  $\mathcal{X} \in \mathcal{A}$ ；
  2.  $A \in \mathcal{A}$ ，则  $A^c \in \mathcal{A}$ （关于补运算封闭）；
  3. 对至多可数集列 $\{A_n\} \subset \mathcal{A}$ ，有 $\bigcup_n A_n \in \mathcal{A}$ （关于可列并封闭）。

此时称二元组 $(\mathcal{A}, \mathcal{X})$ 为可测空间， $\mathcal{A}$ 中的元素称为可测集。

- **定义1.2**：对可测空间 $(\mathcal{A}, \mathcal{X})$ ，定义在 $\mathcal{A}$ 上的非负函数称为测度，若对任意可数两两不交集列 $\{A_n\} \subset \mathcal{A}$ ， $\mu(\bigcup_n A_n) = \sum_n \mu(A_n)$ （称为 $\sigma$ -可加性）。此时三元组 $(\mathcal{A}, \mathcal{X}, \mu)$ 称为测度空间。如果 $\mathcal{X}$ 能被可数个 $\sigma$ -测度有限的事件 $A_n$ 所覆盖，则称 $\mu$ 为 $\sigma$ -有限的。
- **定义1.3**：给定一个测度空间 $(\mathcal{X}, \mathcal{A}, \mu)$ ，定义于 $\mathcal{X}$ 取值为 $\mathbb{R}$ 上的函数 $f$ 称为可测函数，若直线上的任意Borel集 $B$ 在 $f$ 之下的原象是 $\mathcal{A}$ 可测的：

$$\{x \mid f(x) \in B\} =: f^{-1}(B) \in \mathcal{A}.$$

- **定义1.5**：设 $\nu$ 和 $\mu$ 是可测空间 $(\mathcal{X}, \mathcal{A})$ 上的两个测度，称 $\nu$ 关于 $\mu$ 绝对连续（也称 $\nu$ 受控于 $\mu$ ），如果对 $\forall A \in \mathcal{A}$ ， $\mu(A) = 0$ 蕴含着 $\nu(A) = 0$ ，此时记 $\nu \ll \mu$ 。
- **定理1.1**：（Radon-Nikodym定理）设 $\mu$ 和 $\nu$ 是两个 $\sigma$ 有限测度，则 $\nu \ll \mu$ 当且仅当存在一个处处有限非负 $\mathcal{A}$ 可测函数 $f$ ，使得

$$\nu(A) = \int_A f(\omega) d\mu(\omega), \forall A \in \mathcal{A}.$$

如果不计在一个 $\mu$ 零测集上的差异, 则 $f$ 由上式唯一确定, 称其为 $R - N$ 导数, 记为 $dv/d\mu$ 。

- **定义1.8:** 统计模型 $(\Omega, \mathcal{A}, F_\theta), \theta \in \Theta$ 称为参数可识别的, 若 $F_{\theta_1} = F_{\theta_2} \Rightarrow \theta_1 = \theta_2$ 。

(参数若不可识别, 对参数空间进行约束来使得可识别。)

- 给定一个统计模型 $(\Omega, \mathcal{A}, F_\theta), \theta \in \Theta$ , 若 $T$ 为样本 $X_1, \dots, X_n$ 的取值空间 $\Omega$ 到其值域空间 (通常为欧式空间) 上的不依赖于 $\theta$ 的映射, 则称 $T$ 为统计量 (这里的意思是这个 $T$ 的分布可以是依赖 $\theta$ 的)。
- **定义1.9:** 统计量 $T = T(X)$ 称为对 $\theta$ 是辅助统计量, 若其分布与 $\theta$ 无关。
- 指数族与群族

- **定义1.10:** 称 $\mathcal{P}$ 为一个 $k$ 参数指数族, 若从该总体抽得的i.i.d.样本 $X_1, \dots, X_n$ 的联合密度 (相对于测度 $\mu$ ) 有形式

$$f_\theta(x) = h(x) \exp \left[ \sum_{i=1}^k c_i(\theta) T_i(x) - d(\theta) \right]$$

其中 $x$ 为 $n \times 1$ 向量,  $h(x)$ 为非负可测函数,  $c_i(\theta)$ 和 $d(\theta)$ 均为标量,  $k \geq 1$ 。

- **定义1.11:** 对于概率空间 $(\Omega, \mathcal{A}, P)$ , 集合 $\{x \mid \forall A \in \mathcal{A} \text{ 为包含 } x \text{ 的开矩形, } P(A) > 0\}$ 称为概率测度 $P$ 的支撑。
- **定义1.12:** 对一族概率测度 $\mathcal{P} = \{P_\theta, \theta \in \Theta\}$ , 若 $P_\theta$ 的公共支撑 $A_\theta$ 不依赖于 $\theta$  (记公共值为 $A$ ), 则称 $\mathcal{P}$ 有公共的支撑 $A$ 。
  - 注 设点 $x$ 为随机变量 $X$ 的一个支撑点, 则 $X$ 取值于 $x$ 的任何一个领域的概率大于0:  $\forall \epsilon > 0, P(x - \epsilon < X < x + \epsilon) > 0$ 。因此若 $X$ 有逐段连续的密度函数 $f(x)$ , 可证明满足 $f(x) > 0$ 的 $x$ 都是支撑点, 且支撑为 $\{x : f(x) > 0\}$ 的闭包。
  - 对于定义1.10中的指数族, 注意到

$$\{x \mid f_\theta(x) > 0\} = \{x : h(x) > 0\}$$

与 $\theta$ 无关, 故有注知指数族有公共的支撑。

- 注 有公共支撑的分布族也不一定是指数族。
- 为方便起见, 常将指数族分布重新参数化:  $\omega_i = c_i(\theta), i = 1, \dots, k$ , 得到密度的点则化形式:

$$f_\omega(x) = h(x) \exp \left[ \sum_{i=1}^k \omega_i T_i(x) - d(w) \right].$$

典则化形式并不唯一, 事实上, 对 $\omega$ 进行一一变换后所得密度函数也有典则化形式。

- **定义1.13:** 注意到 $f_\omega(x)$ 为密度当且仅当

$$0 < \int h(x) \exp \left[ \sum_{i=1}^k \omega_i T_i(x) \right] d\mu(x) < \infty.$$

满足这种情形的点 $\omega$ 的全体 $\mathcal{W}$ 称为**自然参数空间**,  $\omega$ 称为自然参数。

- 对指数族分布有

$$ET_i = \frac{\partial d(\omega)}{\partial \omega_i}, \text{cov}(T_i, T_j) = \frac{\partial^2 d(\omega)}{\partial \omega_i \partial \omega_j}.$$

- **定义1.14:** 统计量 $T = T(X)$ 对 $\theta$ 称为充分统计量, 若条件分布 $X | T$ 与 $\theta$ 无关。
  - 充分统计量不唯一。设 $T$ 为充分统计量,  $g$ 为任一已知的一一映射, 则 $g(T)$ 也是一个充分统计量;
  - 设 $T$ 是一个充分统计量, 则对任何统计量 $S = S(X)$ , 条件分布 $S | T = t$ 也与 $\theta$ 无关。
- **定理1.3:** (**因子分解定理**) 设分布族 $P_\theta, \theta \in \Theta$ 受控于 $\mu$ , 记 $f_\theta(x) = \frac{dP_\theta}{d\mu}(x)$ , 则 $T = T(X)$ 对 $\theta$ 是充分统计量 $\Leftrightarrow f_\theta(x) = g_\theta[T(X)]h(x), a.s. \mu$ , 其中 $h(x)$ 为非负可测函数。(证明见pptP38或者书上找)
- **定义1.15:** 一个充分统计量 $T$ 称为极小的 (minimal) 若对任一充分统计量 $S$ , 存在 $g$ 使得 $T = g(S), a.s.$ 。
  - **极小充分统计量**在所有充分统计量中最大限度的简化了数据。
- **定理1.4:** 设 $\{F_\theta, \theta \in \Theta\}$ 是一个具有公共支撑的分布族,  $\{F_{\theta'}, \theta' \in \Theta'\}$ 为子族, 即 $\Theta' \subset \Theta$ 。若统计量 $T$ 关于 $F_{\theta'}$ 是极小充分的同时关于 $F_\theta$ 是充分的, 则关于 $F_\theta$ 也是极小充分的。
- **定理1.5:** 设 $\mathcal{F}$ 是有限个具有密度 $f_{\theta_i} (i = 0, 1, \dots, k)$ 的分布构成的族, 其具有公共支撑。
  - 统计量 $S = S(X)$ 是充分统计量 $\Leftrightarrow$ 对任何固定的 $\theta_0$ 和 $\theta$ ,  $\frac{f_\theta(X)}{f_{\theta_0}(X)}$ 是 $S(X)$ 的函数;
  - 统计量 $T(X) = \left( \frac{f_{\theta_1}(X)}{f_{\theta_0}(X)}, \frac{f_{\theta_2}(X)}{f_{\theta_0}(X)}, \dots, \frac{f_{\theta_k}(X)}{f_{\theta_0}(X)} \right)^T$ 是极小充分统计量。
- **推论1.1:** 设 $X$ 的分布具有指数形式

$$f_W(x) = h(x) \exp \left[ \sum_{i=1}^k \omega_i T_i(x) - d(\omega) \right].$$

则当满足下列条件之一时,  $T = T(X) = (T_1, T_2, \dots, T_k)'$ 是极小充分统计量。

- $T_1, T_2, \dots, T_k$ 线性无关 (也等价于自然参数空间 $\mathcal{W}$ 有内点);
- 参数空间含有 $k + 1$ 个点 $\omega^{(0)}, \omega^{(1)}, \dots, \omega^{(k)}$ , 它们张成欧氏空间 $\mathbb{R}^k$ 。
- **推论1.6:** 设分布族 $\{P_\theta, \theta \in \Theta\}$ 受控于 $\mu$ , 记

$$f_{\theta}(x) = \frac{dP_{\theta}}{d\mu}(x),$$

若

$$\frac{f_{\theta}(x)}{f_{\theta}(y)} \text{ 与 } \theta \text{ 无关} \Leftrightarrow T(x) = T(y),$$

则  $T = T(x)$  是极小充分统计量。

- **定义1.16:** 给定一个统计模型  $\{(\Omega, \mathcal{A}, P_{\theta}), \theta \in \Theta\}$ 。  $T = T(X)$  称为完全统计量，若对任何满足条件  $E_{\theta}g(T) = 0, \forall \theta \in \Theta$  的  $g$  必有  $P_{\theta}(g(T) = 0) = 1, \forall \theta \in \Theta$  (或者  $g(T) = 0, a.s. P_{\theta}, \forall \theta \in \Theta$ )。
- 若上述命题对任何有界  $g$  成立，则称  $T$  为有界完全统计量。
- **定理1.7: (Basu)** 若  $T$  是关于分布族  $\{P_{\theta}, \theta \in \Theta\}$  的完全充分统计量，则任一辅助统计量  $S$  都与  $T$  独立。(证明在ppt P50)
- **定理1.8:** 若极小充分统计量存在，则一个完全充分统计量必定是极小的。(证明在ppt P51)
  - 其逆定理不存在，即便是极小充分统计量存在，它不一定是完全统计量。
- **定理1.9:** 设  $X$  的分布具有指数族形式

$$f_{\omega}(x) = h(x) \exp \left[ \sum_{i=1}^k \omega_i T_i(x) - d(\omega) \right].$$

且自然参数空间  $\mathcal{W}$  有内点，则  $T = (T_1, T_2, \dots, T_k)^T$  是完全的。

- 随机变量序列的收敛性
  - 若随机变量序列  $\{X_n\}$  依概率有界，则记为  $X_n = O_p(1)$ ;
  - **依概率有界:** 对  $\forall \varepsilon > 0, \exists M_{\varepsilon}$  使得  $P(|X_n| \geq M_{\varepsilon}) \leq \varepsilon$ 。
  - 若随机变量序列  $\{X_n\}$  依概率收敛，则记为  $X_n = o_p(1)$ ;
  - **依概率收敛:**  $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0$ 。
  - $X_n = O_p(Y_n)$  当且仅当  $X_n/Y_n = O_p(1)$ ;
  - $X_n = o_p(Y_n)$  当且仅当  $X_n/Y_n = o_p(1)$ ;
  - $X_n = o(Y_n)$  当且仅当  $X_n/Y_n = o(1)$ 。
  - 若  $X_n \xrightarrow{d.f.} X$ ，则  $X_n = O_p(1)$ 。
  - $O_p(1) \times o_p(1) = o_p(1)$ 。
- **定理1.10: (Slutsky's Theorem)** 设随机变量序列  $\{X_n\}, \{Y_n\}$  满足  $X_n \xrightarrow{d.f.} X, Y_n \xrightarrow{Pr.} c$  (常数)，则
  - $X_n + Y_n \xrightarrow{d.f.} X + c$ ;

- $X_n Y_n \xrightarrow{d.f.} cX$ ;
  - $\frac{X_n}{Y_n} \xrightarrow{d.f.} \frac{X}{c}, (c \neq 0)$ 。
- 设随机变量序列  $X_n \xrightarrow{Pr.} c$ , 函数  $g$  在  $c$  处连续, 则  $g(X_n) \xrightarrow{Pr.} g(c)$ 。
- Wald统计决策理论简介 (P57-P69)
  - **可容许性**: 设两个决策函数  $\delta_0, \delta$  满足

$$R_\theta(\delta_0) \leq R_\theta(\delta), \forall \theta \in \Theta,$$

则称  $\delta_0$  一致的优于  $\delta$ 。若至少对某个  $\theta$  成立严格不等式, 则称  $\delta_0$  严格一致的优于  $\delta$ , 此时称  $\delta$  是 **不可容许的**。若不存在这样的  $\delta_0$ , 则称  $\delta$  是 **可容许的**。

- 秩序统计量及有关分布 (P70)
  - $X_{(i)}$  的分布和密度

$$F_i(x) = \frac{n!}{(i-1)!(n-i)!} \int_0^{F(x)} t^{i-1} (1-t)^{n-i} dt,$$

密度为

$$f_i(x) = \frac{n!}{(i-1)!(n-i)!} [F(x)]^{i-1} [1-F(x)]^{n-i} f(x).$$

- $(X_{(i)}, X_{(j)})$  的联合密度 ( $1 \leq i < j \leq n$ ) 当  $u < v$  时

$$f_{ij}(u, v) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(u)]^{i-1} [F(v) - F(u)]^{j-i-1} [1-F(v)]^{n-j} f(u) f(v).$$

当  $u \geq v$  时,  $f_{ij}(u, v) = 0$ 。

- **定理1.11**: 设  $0 < p_1 < p_2 < \dots < p_k < 1$ ,  $X_1, X_2, \dots, X_n \sim F(x)$  为 i.i.d 样本, 密度  $f(X)$  在  $p_i$  处有连续的非零导数, 则若  $n_i = np_i + o(n^{1/2}), 1 \leq i \leq k$ , 有

$$\sqrt{n}(X_{(n_1)} - \lambda_{p_1}, \dots, X_{(n_k)} - \lambda_{p_k})^T \xrightarrow{d.f.} N(0, \Lambda),$$

其中  $\Lambda$  为  $k$  阶对称方阵, 其  $(i, j)$  元素为

$$\frac{p_i(1-p_j)}{f(\lambda_{p_i})f(\lambda_{p_j})}.$$

## 第二章

- **定义2.1:** 估计 $\hat{\theta}$ 的偏倚 (bias) 定义为

$$\text{Bias}_{\theta}(\hat{\theta}) = E_{\theta}\hat{\theta} - \theta.$$

一个估计称为无偏的 (unbiased) 若

$$\text{Bias}_{\theta}(\hat{\theta}) = 0 \text{ 即 } E_{\theta}\hat{\theta} = \theta.$$

无偏估计不具有变换不变性, 即 $\hat{\theta}$ 为 $\theta$ 的无偏估计, 通常 $g(\hat{\theta})$ 不是 $g(\theta)$ 的无偏估计, 除非 $g$ 是线性的。

- **定义2.2:** 估计 $\hat{\theta}$ 的平均绝对误差 (mean absolute error, MAE) 定义为

$$\text{MAE}_{\theta}(\hat{\theta}) = E_{\theta}|\hat{\theta} - \theta|;$$

均方误差 (mean square error, MSE) 定义为

$$\text{MSE}_{\theta}(\hat{\theta}) = E_{\theta}(\hat{\theta} - \theta)^2.$$

。

$$\text{MSE}_{\theta}(\hat{\theta}) = \text{var}_{\theta}(\hat{\theta}) + [\text{Bias}_{\theta}(\hat{\theta})]^2.$$

- **定义2.3:** 估计序列 $\{\hat{\theta}_n\}$ 称为 $\theta$ 的 (弱) 相合估计 (consistent estimator), 如果 $\hat{\theta}_n$ 依概率收敛到 $\theta$ , 即

$$\lim_{n \rightarrow \infty} P_{\theta}(|\hat{\theta}_n - \theta| > \varepsilon) = 0, \quad \forall \varepsilon > 0, \theta \in \Theta.$$

若 $P_{\theta}(\lim_{n \rightarrow \infty} \hat{\theta}_n = \theta) = 1$ , 则称 $\hat{\theta}_n$ 是 $\theta$ 的强相合估计。

相合性的意义: 只要样本量充分大, 就可以使估计误差在一定意义下充分地小; 如果一个估计量没有相合性, 则无论用多少样本估计都会产生系统误差。

- **定义2.4:** 设 $\hat{\theta}_n$ 为 $\theta$ 的估计, 若存在 $\sigma_n^2(\theta)$ 满足 $\sigma_n^{-1}(\theta)(\hat{\theta}_n - \theta) \xrightarrow{d.f.} N(0, 1)$ , 则称估计 $\hat{\theta}_n$ 具有渐近正态性, 记为

$$\hat{\theta}_n \sim \text{AN}(\theta, \sigma_n^2(\theta)),$$

$\sigma_n^2(\theta)$ 称为渐近方差。(若某个无偏估计的方差达到此下界, 则此估计必为UMVUE)

- **替代原理** (P12-P25)

◦ 怎样估计F?

- $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x)$ , 经验分布函数 (P17)。
- $\hat{\theta} = T(\hat{F}_n) = \frac{1}{n} \sum_{i=1}^n h(X_i)$ 。
- 核密度估计

◦ 替代原理能否得到好的估计 $\hat{\theta}$ ?

◦ 矩估计方法

• 一致最小方差无偏估计

◦ **定义2.5:** 设 $T$ 是参数 $g(\theta)$ 的无偏估计, 称 $T$ 为一个UMVUE, 如果对 $g(\theta)$ 的任意无偏估计 $S$ 满足如下不等式:

$$\text{var}_{\theta}(T) \leq \text{var}_{\theta}(S), \forall \theta,$$

◦  $g(\theta)$ 的无偏估计可能不存在

◦ 例: 设 $X \sim B(n, p)$ ,  $0 < p < 1$ , 则  $g(p) = p^{-1}$ 的无偏估计不存在 (证明在P27)。

◦ 一些时候无偏估计存在但是没有任何意义 (P28)

◦ **定理2.1: (Rao-Blackwell定理)** 设 $T = T(X)$  是  $\theta$ 的充分统计量, 令 $S = S(X)$  为  $g(\theta)$ 的无偏估计且对 $\forall \theta \in \Theta$  有  $\text{var}_{\theta}(S) < \infty$ , 则 $S^* = E(S | T)$  是  $g(\theta)$ 的无偏估计, 且对 $\forall \theta \in \Theta$  有  $\text{var}_{\theta}(S^*) \leq \text{var}_{\theta}(S)$ , “=” 成立  $\Leftrightarrow P_{\theta}(S^* = S) = 1$ 。(证明P29)

▪ 即说明只用在充分统计量中寻找UMVUE。

$$\text{▪ } E_{\theta} S^* = E_{\theta}[E(S | T)] = E_{\theta} S = g(\theta), \forall \theta \in \Theta,$$

$$\text{var}_{\theta}(S) = E_{\theta}(S - E_{\theta} S)^2 = E_{\theta}(S - E(S | T) + E(S | T) - E_{\theta} S)^2$$

$$\text{▪ } = E_{\theta}(S - E(S | T))^2 + E_{\theta}(E(S | T) - E_{\theta} S)^2 \\ + 2E_{\theta}[(S - E(S | T))(E(S | T) - E_{\theta} S)]$$

$$E_{\theta}[(S - E(S | T))(E(S | T) - E_{\theta} S)]$$

$$= E_{\theta} \{E_{\theta}(S - E(S | T))(E(S | T) - E_{\theta} S) | T\}$$

$$\text{▪ } = E_{\theta} \{(E(S | T) - E_{\theta} S)(E_{\theta}((S - E(S | T)) | T))\} \\ = 0$$

• **推论2.1:** 设 $S$  为  $g(\theta)$ 的无偏估计且对 $\forall \theta \in \Theta$  有  $\text{var}_{\theta}(S) < \infty$ ,  $T_1$ 和 $T_2$ 都是充分统计量且 $T_2 = h(T_1)$ , 令 $S_1^* = E(S | T_1)$ ,  $S_2^* = E(S | T_2)$ , 则对 $\forall \theta \in \Theta$ 有 $\text{var}_{\theta}(S_1^*) \geq \text{var}_{\theta}(S_2^*)$ 。

◦ 若极小充分统计量存在, 则 $\theta$ 的UMVUE必有形式 $E(S | T)$ 。

◦ 不同的无偏估计对应的条件期望不一定是UMVUE。 (P31)

• **定理2.2: (Lehmann-Scheffe定理)** 设 $T$ 是充分完全统计量,  $S$ 为 $g(\theta)$ 的无偏估计且对 $\forall \theta \in \Theta$ 有 $\text{var}_{\theta}(S) < \infty$ 。令 $S^* = E(S | T)$ , 则 $S^*$ 为UMVUE。 $S^*$  和  $T^*$ 为UMVUE  $\Rightarrow P_{\theta}(S^* = T^*) = 1, \theta \in \Theta$ , 即UMVUE是以概率1地唯一的。(证明P32)

◦ 解方程 (找函数 $h$ 使得 $E_{\theta} h(T) = g(\theta)$ )

◦ 条件化（先找一个无偏估计 $S$ ）

- **定理2.3:** 设 $T = T(X)$ 为 $g(\theta)$ 的无偏估计且对 $\forall \theta \in \Theta$ 有 $\text{var}_\theta(T) < \infty$ 。令 $\mathcal{U}$ 为所有方差有限的0的无偏估计，则 $T$ 为UMVUE的充分必要条件是对于 $\forall U \in \mathcal{U}$ 有 $E_\theta[T(X)U(X)] = 0, \forall \theta \in \Theta$ 。（证明P35）
- 对 $\forall U$ 如 $EU^2 < \infty$ ，则

$$\text{var}_\theta(S) \geq \frac{[\text{cov}_\theta(S, U)]^2}{\text{var}_\theta(U)}.$$

- **定理2.4:** (Cramer-Rao下界) 设 $X \sim f(x, \theta)$ ，统计量 $T$ 为 $g(\theta)$ 的无偏估计，对 $\forall \theta \in \Theta$ 有 $\text{var}_\theta(T) < \infty, g(\theta)$ 可导。若满足如下两个条件：
  - 分布支撑 $A = \{x \mid f(x, \theta) > 0\}$ 不依赖于 $\theta$ ；
  - 对 $\forall x \in A, f(x, \theta)$ 关于 $\theta$ 可导，且导数

$$\frac{\partial}{\partial \theta} \int f(x, \theta) dx \text{ 和 } \frac{\partial}{\partial \theta} \int T(x) f(x, \theta) dx$$

中求导与积分可交换顺序。

则 $\text{var}_\theta(T) \geq I^{-1}(\theta)[g'(\theta)]^2$ ，其中 $I(\theta) = E_\theta\left(\frac{\partial}{\partial \theta} \log f(X, \theta)\right)^2$ 称为**Fisher信息量**。（证明P38）（注意这里不是对样本，而是对单一的 $X$ ）

- **定理2.5:** （证明P39）能取到C-R下界当且仅当分布属于单参数指数族。（ $T$ 为其中充分统计量）。
- 随机样本 $X$ ，若其方差 $\text{var}(X) = \sigma^2$ 存在，则称 $\sigma$ 为该总体的标准差；而一个估计量 $\hat{\theta}$ 的标准误。
- $\delta$ 法（delta method）：设随机变量序列 $X_n$ 满足

$$\sqrt{n}(X_n - \theta) \xrightarrow{d.f.} N(0, \sigma^2)$$

则对任意函数 $g$ ，如满足 $g'(\theta)$ 存在且 $g'$ 在 $\theta$ 处连续，则有

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{d.f.} N(0, [g'(\theta)]^2 \sigma^2).$$

- 极大似然估计
  - 若 $T = T(X)$ 是 $\theta$ 的充分统计量且 $\theta$ 的MLE $\hat{\theta}$ 存在唯一，则 $\hat{\theta}$ 为 $T$ 的函数；
  - MLE具有某种不变性。若 $\phi = g(\theta)$ 为 $\Theta$ 上的严格增函数（推广后任意函数皆可），则若 $\hat{\theta}$ 为 $\theta$ 的MLE， $g(\hat{\theta})$ 必为 $\phi$ 的MLE。
  - 求解MLE的方法
    - 直接极大法
    - 似然方程法： $s(\theta) = \frac{\partial l(\theta)}{\partial \theta}$ 称为得分函数。似然方程即 $s(\theta) = 0$ 。
  - Jensen不等式： $g$ 严格凸函数， $EX$ 存在，则 $Eg(X) \geq g(EX)$ 。



- 以下总假定  $X_1, X_2, \dots, X_n \sim f(x, \theta), l(\theta) = \sum_{i=1}^n \log f(X_i, \theta)$  为对数似然, 假定条件
  - $\Theta$  为开集;
  - $A = \{x : f(x, \theta) > 0\}$  不依赖于  $\theta$ ;
  - 对固定  $x \in A, f(x, \theta)$  关于  $\theta$  有三阶连续导数;
  - $\forall \theta \in \Theta$  有  $E_\theta[\frac{\partial}{\partial \theta} \log f(X_i, \theta)] = 0$ , 记

$$I(\theta) = \text{var}_\theta \left( \frac{\partial}{\partial \theta} \log f(X_i, \theta) \right)$$

假设  $0 < I(\theta) < \infty$ ;

- $\forall \theta \in \Theta$ , 记  $J(\theta) = -E_\theta[\frac{\partial^2}{\partial \theta^2} \log f(X_i, \theta)]$ , 假设  $0 < J(\theta) < \infty$ ;
- 对任意给定  $\theta$  和  $\delta > 0, \exists M(x)$ , 使得当  $|t - \theta| < \delta$  时  $|\frac{\partial^3}{\partial \theta^3} \log f(x, \theta)|_{\theta=t} \leq M(x)$  且  $E_\theta M(X_i) < \infty$ 。
- 若假定  $\int f(x, \theta) dx$  关于  $\theta$  的偏导数可在积分下二次求导, 则  $I(\theta) = J(\theta)$ 。
- **定理2.5 (P62)** : 设条件A1, A2满足,  $f(x, \theta)$  关于  $\theta$  可导, 则  $n \rightarrow \infty$  时, 似然方程  $\sum_{i=1}^n \frac{\partial \log f(X_i, \theta)}{\partial \theta} = 0$  以概率1的存在一个解  $\hat{\theta}_n$ , 此解  $\hat{\theta}_n$  为  $\theta$  的相合估计。此外若条件A1-A6成立, 则似然方程任一相合解序列  $\hat{\theta}_n$  满足  $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d.f.} N(0, \frac{I(\theta)}{J^2(\theta)})$ 。
- MLE的标准差
  - 若  $I(\theta)$  有显式表达式, 则用  $\hat{\theta}_n$  代替  $\theta$ , 这样得到  $I(\theta)$  的估计为  $I(\hat{\theta}_n)$ , 从而  $\hat{\theta}_n$  的标准差估计为

$$\widehat{\text{SE}}(\hat{\theta}_n) = [nI(\hat{\theta}_n)]^{-\frac{1}{2}}.$$

称  $nI(\hat{\theta}_n)$  为  $\theta$  的期望Fisher信息。

- 由于

$$I(\theta) = -E_\theta \frac{\partial^2 \log f(X_i, \theta)}{\partial \theta^2},$$

故可用

$$\hat{I}(\hat{\theta}_n) = -\frac{1}{n} \sum_{i=1}^n \frac{\partial^2 \log f(X_i, \theta)}{\partial \theta^2} \Big|_{\theta=\hat{\theta}_n} = -\frac{1}{n} \frac{\partial^2 l(\theta)}{\partial \theta^2} \Big|_{\theta=\hat{\theta}_n}$$

来估计  $I(\theta)$ 。从而  $\hat{\theta}_n$  的标准差估计为

$$\widehat{\text{SE}}(\hat{\theta}_n) = \left( -\frac{\partial^2 l(\theta)}{\partial \theta^2} \Big|_{\theta=\hat{\theta}_n} \right)^{-\frac{1}{2}}$$

称  $n\hat{I}(\theta_n) = -\frac{\partial^2 l(\theta)}{\partial \theta^2} \Big|_{\theta=\hat{\theta}_n}$  为  $\theta$  的观测Fisher信息。

- 多维情形类似 (P68-P75)

## • MLEs数值计算

### ◦ Newton-Raphson算法

- 记负对数似然函数的Hessian矩阵为  $H(\theta) = -\frac{\partial^2 l(\theta)}{\partial \theta \partial \theta'} = -\frac{\partial s(\theta)}{\partial \theta'}$ 。
- 第0步：令  $k=0$ ，选初始值  $\hat{\theta}^{(k)}$ ；
- 第1步：  $\hat{\theta}^{(k+1)} = \hat{\theta}^{(k)} + \left[ H(\hat{\theta}^{(k)}) \right]^{-1} s(\hat{\theta}^{(k)})$ ；
- 第2步：若  $|s(\hat{\theta}^{(k)})|$  或  $|\hat{\theta}^{(k+1)} - \hat{\theta}^{(k)}|$  充分小，则停止；否则  $k=k+1$ ，转到第1步。  
(证明在P77，以及一步迭代法)

### ◦ Fisher得分算法

- 将Newton-Raphson算法中  $H(\theta) = -\frac{\partial^2 l(\theta)}{\partial \theta \partial \theta'}$  换成  $H^*(\theta) = E_{\theta} H(\theta) = -E_{\theta} \frac{\partial^2 l(\theta)}{\partial \theta \partial \theta'}$  就得到Fisher得分算法，即

$$\hat{\theta}^{(k+1)} = \hat{\theta}^{(k)} + \left[ H^*(\hat{\theta}^{(k)}) \right]^{-1} s(\hat{\theta}^{(k)}).$$

即在迭代算法中，Newton-Raphson算法用的是观测Fisher信息矩阵而在Fisher得分算法中用的是期望Fisher信息矩阵。

- 利用Newton-Raphson算法需要指定  $\theta$  的初始值  $\hat{\theta}^{(0)}$ 。初始值  $\hat{\theta}^{(0)}$  的选取对算法收敛性有较大影响。
- 可以通过粗略方法例如矩方法得到估计值的初始值  $\hat{\theta}^{(0)}$ 。
- 两个算法的比较 (P81)
- (P98 **定理2.7**) 若  $\tilde{\theta}$  是  $\theta$  的  $\sqrt{n}$ -相合，则Newton-Raphson和Fisher得分的一步迭代是渐近有效的。
- **EM算法** (P83)
- 渐近相对效率和渐近有效性
  - **定义2.7**：设  $\hat{\theta}_n, \tilde{\theta}_n$  是基于样本  $X_1, X_2, \dots, X_n$  的  $\theta$  的两个估计，且  $\hat{\theta}_n \sim \text{AN}(\theta, \sigma_{1n}^2(\theta))$ ,  $\tilde{\theta}_n \sim \text{AN}(\theta, \sigma_{2n}^2(\theta))$ ，则  $\hat{\theta}_n$  相比于  $\tilde{\theta}_n$  的渐近相对效率定义为

$$\text{ARE}_{\theta}(\hat{\theta}_n, \tilde{\theta}_n) = \lim_{n \rightarrow \infty} \frac{\sigma_{2n}^2(\theta)}{\sigma_{1n}^2(\theta)}$$

(若极限存在)

- **定义2.8**: 若估计序列 $\hat{\theta}_n$ 满足 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d.f.} N(0, [I(\theta)]^{-1})$ , 则称 $\hat{\theta}_n$ 是渐近有效的。
- 若对某个 $\theta_0 \in \Theta$ , 渐近正态的方差 $\sigma^2(\theta_0) < [I(\theta_0)]^{-1}$ , 则称 $\hat{\theta}_n$ 为超有效估计。
- **定义2.9**: 估计序列 $\hat{\theta}_n$ 称为 $\theta$ 的 $\sqrt{n}$ -相合估计, 若 $\sqrt{n}(\hat{\theta}_n - \theta) = O_p(1)$ 。

• **Stein现象** (P104, 在平方损失的意义下最小风险, UMVUE不可容许)

• **不变估计**

- 设统计模型 $(\Omega, \mathcal{B}, P_\theta), \theta \in \Theta$ 。变换 $g: \Omega \rightarrow \Omega$ 为1-1, 且对每个 $\theta \in \Theta$ , 当 $X \sim P_\theta$ 时,  $gX \sim P_{\theta^*}$ , 若 $\theta$ 取遍空间 $\Theta$ 时,  $\theta^*$ 也取遍空间 $\Theta$ , 则称模型在变换 $g$ 下是不变的 (invariant)。若对变换群 $G$ 中任一变换 $g$ 都是不变的, 则称模型在变换群 $G$ 下是不变的。
- 由 $g$ 可以诱导出一个映射 $g^*: \Theta \rightarrow \Theta, g^*\theta = \theta^*$ 。诱导变换 $g^*$ 是 $\Theta$ 上的1-1变换;
- $G^* = \{g^*: g \in G\}$ 形成一个群。
- $g$ 是针对 $X$ 的映射。
- 对损失函数 $L(a, \theta), a \in A$ 为行动空间, 若对任意的 $g \in G$ , 存在唯一的 $a^* \in A$ 使得 $L(a, \theta) = L(a^*, g^*\theta), \forall \theta \in \Theta$ 则称损失函数在变换群 $G$ 下是不变的。
- 由 $g$ 可以诱导出一个映射 $g^{**}: A \rightarrow A, g^{**}a = a^*$ 。
- 一个估计量 $\hat{\theta}$ 满足 $\hat{\theta}(gX) = g^{**}\hat{\theta}(X), \forall g \in G$ , 则称 $\hat{\theta}$ 在变换群 $G$ 下是不变估计。
- **定义**若 $\hat{\theta}$ 为一个不变估计, 它在所有不变估计中有最小的risk, 则 $\hat{\theta}$ 称为MRIE (minimum risk invariant estimator)。
- **位置参数的不变估计**:

▪ P110

▪ **Pitman估计**

▪ 
$$\hat{\theta}^* = \frac{\int_{-\infty}^{\infty} t f(X_1 - t, X_2 - t, \dots, X_n - t) dt}{\int_{-\infty}^{\infty} f(X_1 - t, X_2 - t, \dots, X_n - t) dt}.$$

▪ 例子在P114, 多看作业解答。

◦ **刻度参数的不变估计**:

▪ P115

▪ **Pitman估计**

▪ 
$$\hat{\theta}^* = \frac{\int_{-\infty}^{\infty} t^{n+h-1} f(tX_1, tX_2, \dots, tX_n) dt}{\int_{-\infty}^{\infty} t^{n+2h-1} f(tX_1, tX_2, \dots, tX_n) dt}.$$

▪ 例子在P121, 多看作业解答。

## 第三章

- $H_0$ 为原假设,  $H_1$ 为备择假设。一个假设称为简单的, 若只包含一个点, 否则称为复合的。

- 可测函数 $\phi$ 称为**检验函数**，若 $\theta \in \Theta_0$ ，则 $\phi(X) = 0$ ，若 $\theta \in \Theta_1$ ，则 $\phi(X) = 1$ 。 $\phi$ 通过某个统计量 $T = T(X)$ 而依赖于 $X$ ，称 $T$ 为检验统计量。检验函数 $\phi$ 把样本空间分成两个不交的集合 $\Omega_A = \{X \mid \phi(X) = 0\}$ ， $\Omega_R = \{X \mid \phi(X) = 1\}$ ，分别称为**接受域**和**拒绝域**。
- **(拒真)** 若 $\theta \in \Theta_0$ ，但 $\phi(X) = 1$ ，称为检验 $\phi$ 的**第I类错误 (type I error)**，其发生的概率为 $P_\theta(\phi(X) = 1) = E_\theta \phi(X)$ ， $\theta \in \Theta_0$ ；
- **(取伪)** 若 $\theta \in \Theta_1$ ，但 $\phi(X) = 0$ 称为检验 $\phi$ 的**第II类错误 (type II error)** 其发生的概率为 $P_\theta(\phi(X) = 0) = 1 - E_\theta \phi(X)$ ， $\theta \in \Theta_1$ 。
- **例3.2:** 设两个检验函数 $\phi_1, \phi_2$ ，记 $R_i = \{X \mid \phi_i(X) = 1\}$ 。设 $R_1 \subset R_2$ ，这意味着 $E_\theta \phi_1(X) \leq E_\theta \phi_2(X)$ ， $\forall \theta \in \Theta$ 。因此 $1 - E_\theta \phi_1(X) \geq 1 - E_\theta \phi_2(X)$ ， $\forall \theta \in \Theta$ 。这表明，当 $\theta \in \Theta_0$ 时，欲减少犯第I类错误的概率，在 $\theta \in \Theta_1$ 时就会增加犯第II类错误的概率。
- 经典做法给定 $\alpha \in [0, 1]$ ，使检验 $\phi$ 满足 $E_\theta \phi(X) \leq \alpha$ ， $\forall \theta \in \Theta_0$ ，即控制第I类错误的概率 $\leq \alpha$ ， $\alpha$ 称为检验 $\phi$ 的显著性水平。然后在此基础上减少犯第II类错误的概率。
- **功效函数**：对给定的检验函数，令 $\beta(\theta) = E_\theta \phi(X)$ ，作为 $\theta \in \Theta$ 傻姑娘的函数，称为检验 $\phi$ 的功效函数 (power function) 。
  - 若 $\theta \in \Theta_1$ ，称 $\beta(\theta)$ 为检验 $\phi$ 在 $\theta$ 处的功效 (power) 。
  - 水平为 $\alpha$ 的检验，即要求 $\beta(\theta) \leq \alpha$ ， $\forall \theta \in \Theta_0$ 。
- **一致最优检验 (UMP检验)**
  - **定义3.1:** 水平为 $\alpha$ 的检验 $\phi^*$ 称为一致最优检验 (uniformly most powerful test) 若对任一水平为 $\alpha$ 的检验 $\phi$ ， $\forall \theta \in \Theta_1$ ， $\beta_{\phi^*}(\theta) \geq \beta_\phi(\theta)$ 。(即第II类错误概率最小的检验)
  - **引理3.1:** 设 $T = T(X)$ 为 $\theta$ 的充分统计量，则对任意检验函数 $\phi(X)$ ，存在只依赖于 $T$ 的检验函数与 $\phi$ 有相同的功效函数。(所以找UMP只要在充分统计量构成的检验中去寻找即可)
  - 对于 $H_0$  和  $H_1$  都为简单模型，**定理3.1**给出UMP检验存在性以及唯一性。
    - $\forall \alpha \in [0, 1]$ ，存在水平为 $\alpha$ 的UMP检验 $\phi^*$ ，满足

$$\phi^*(X) = \begin{cases} 1 & f_1(X) > k f_0(X) \\ \gamma & f_1(X) = k f_0(X) \\ 0 & f_1(X) < k f_0(X) \end{cases}$$

这里 $\gamma \in [0, 1]$ ， $k \geq 0$ 为常数 (可为 $\infty$ ) 且使得 $E_{\theta_0} \phi^*(X) = \alpha$ 。

- **引理3.2:** 设水平为 $\alpha$ 的检验 $\phi^*$ ，若对 $\forall \theta_1 \in \Theta_1$ 的检验问题 $H_0 : \theta \in \Theta_0$  v.s.  $H_1 : \theta = \theta_1$ 都是UMP检验，则 $\phi^*$ 为检验问题 $H_0 : \theta \in \Theta_0$  v.s.  $H_1 : \theta \in \Theta_1$ 的UMP检验。
- **定义3.2:** 分布族 $F(x, \theta)$ ， $\theta \in \Theta \subset R$  (密度为 $f(x, \theta)$ ) 称为**单调似然比**分布族 (MLR族)，若存在实值统计量 $T = T(x)$ 使得对 $\forall \theta_1 < \theta_2$ ， $\frac{f(x, \theta_2)}{f(x, \theta_1)}$ 是 $T(x)$ 的非降函数。(  $T(x)$ 是 $\theta$ 的充分统计量)
  - 设 $X$ 为单参数指数分布族 $f(x, \theta) = \exp[c(\theta)T(x) - b(\theta) + s(x)]$ ， $x \in A$ ，假设 $c(\theta)$ 为 $\theta$ 的严格增函数，则其为MLR族。

- **引理3.3:** 设  $X \sim f(x, \theta)$  对统计量  $T = T(x)$  具有MLR, 若  $\phi$  为  $T$  的非降函数, 则  $E_\theta \phi(T)$  为  $\theta$  的非降函数。
- **定理3.2:** 设  $X \sim f(x, \theta)$  关于统计量  $T = T(x)$  为MLR, 考察检验问题  $H_0 : \theta \leq \theta_0$  v.s.  $H_1 : \theta > \theta_0$ ,  
 ■ 令

$$\phi^*(X) = \begin{cases} 1 & T(X) > k \\ \gamma & T(X) = k \\ 0 & T(X) < k \end{cases}$$

此处  $k, \gamma$  由  $E_{\theta_0} \phi^*(X) = \alpha$  确定, 则  $\phi^*(X)$  为水平为  $\alpha$  的UMP检验。

- $\beta_{\phi^*}(\theta)$  为集合  $\{\theta \in \Theta \mid 0 < \beta_{\phi^*}(\theta) < 1\}$  上的严格增函数。
- 对任何满足  $E_{\theta_0} \phi(X) = \alpha$  的检验, 以及  $\theta < \theta_0, \theta \in \Theta, E_\theta \phi^*(X) \leq E_\theta \phi(X)$ 。  
 (MLR族也使得犯第I类错误的概率一致的小)
- 对检验问题  $H_0 : \theta = \theta_0$  v.s.  $H_1 : \theta > \theta_0$  本定理结论仍然成立。
- 对检验问题  $H_0 : \theta \geq \theta_0$  v.s.  $H_1 : \theta < \theta_0$  或  $H_0 : \theta = \theta_0$  v.s.  $H_1 : \theta < \theta_0$  只要将最上面的不等号方向变向且把第二个中的“严格增”改为“严格减”。
- **引理3.4:** 设  $f_i, i = 1, 2, \dots, m+1$  为  $(\Omega, \mathcal{B}, \mu)$  上的可积函数, 对给定常数  $t_i, i = 1, 2, \dots$ 。令可测函数集合

$$\Psi = \left\{ \phi \mid 0 \leq \phi \leq 1, \int \phi f_i d\mu \leq t_i, 1 \leq i \leq m \right\}$$

$$\Psi_0 = \left\{ \phi \mid 0 \leq \phi \leq 1, \int \phi f_i d\mu = t_i, 1 \leq i \leq m \right\}$$

设  $\Psi_0$  非空。

- 若存在常数  $k_i, 1 \leq i \leq m$  使得

$$\phi^* = \begin{cases} 1 & f_{m+1} > \sum_{i=1}^m k_i f_i \\ 0 & f_{m+1} < \sum_{i=1}^m k_i f_i \end{cases},$$

且  $\phi^* \in \Psi_0$ , 则  $\int \phi^* f_{m+1} d\mu = \sup_{\phi \in \Psi_0} \int \phi f_{m+1} d\mu$ 。此外若所有的  $k_i \geq 0$ , 则  $\int \phi^* f_{m+1} d\mu = \sup_{\phi \in \Psi} \int \phi f_{m+1} d\mu$ 。

- 令  $M = \{(\int \phi f_1 d\mu, \int \phi f_2 d\mu, \dots, \int \phi f_m d\mu) \mid 0 \leq \phi \leq 1\}$ , 则  $M$  为  $R^m$  中的有界闭凸集。且若  $(t_1, t_2, \dots, t_m)$  为  $M$  的内点, 则存在常数  $k_i, 1 \leq i \leq m$ , 使得上述形式的  $\phi^* \in \Psi_0$ 。
- **定理3.3:** 设  $X$  为单参数指数分布族  $f(x, \theta) = \exp[c(\theta)t(x) - b(\theta) + s(x)], x \in A$ , 假设  $c(\theta)$  为  $\theta$  的严格增函数, 考察检验问题  $H_0 : \theta \leq \theta_1 \text{ or } \theta \geq \theta_2 \text{ v.s. } H_1 : \theta_1 < \theta < \theta_2$ , 令

$$\phi^*(X) = \begin{cases} 1 & k_1 < T(X) < k_2 \\ \gamma_i & T(X) = k_i, i = 1, 2 \\ 0 & T(X) < k_1 \text{ or } T(X) > k_2 \end{cases}$$

- 此时  $k_i, \gamma_i$  由  $E_{\theta_1} \phi^*(X) = E_{\theta_2} \phi^*(X) = \alpha$  确定, 则  $\phi^*(X)$  为水平  $\alpha$  的 UMP 检验。
- 对任何满足  $E_{\theta_1} \phi(X) = E_{\theta_2} \phi(X) = \alpha$  的检验以及  $\theta < \theta_1 \text{ or } \theta > \theta_2, \theta \in \Theta, E_{\theta} \phi^*(X) \leq E_{\theta} \phi(X)$ 。

#### • 一致最优无偏检验

- **定义3.3:** 给定水平  $\alpha$ , 对检验问题  $H_0 : \theta \in \Theta_0 \text{ v.s. } H_1 : \theta \in \Theta_1$ , 称检验  $\phi$  在水平  $\alpha$  下是**无偏的**, 若  $\beta_{\phi}(\theta) \leq \alpha, \forall \theta \in \Theta_0$ , 且  $\beta_{\phi}(\theta) \geq \alpha, \forall \theta \in \Theta_1$ 。
- **定义3.4:** 若对任水平  $\alpha$  的无偏检验  $\phi$ , 存在水平  $\alpha$  的无偏检验  $\phi^*$  使得  $\beta_{\phi}(\theta) \leq \beta_{\phi^*}(\theta), \forall \theta \in \Theta_1$ , 则称  $\phi^*$  为水平  $\alpha$  的一致最优无偏检验 (UMPU)。
- **定义3.5:** 给定水平  $\alpha$ , 检验  $\phi$  称为对于集  $\partial\Theta_{01}$  是相似的若  $\beta_{\phi}(\theta) = \alpha, \forall \theta \in \partial\Theta_{01}$ 。
- **引理3.5:** 若对每一个检验  $\phi, \beta_{\phi}(\theta)$  为  $\theta$  的连续函数。若检验  $\phi^*$  为水平  $\alpha$  的相似检验中一致最优 (功效最大), 则  $\phi^*$  为水平  $\alpha$  的 UMPU 检验。
- **定义3.6:** 设统计量  $T$  对于分布族  $P_{\theta}, \theta \in \partial\Theta_{01}$  是充分的, 若检验函数  $\phi$  满足  $E_{\theta}(\phi(X) \mid T) = \alpha, a.s. P_{\theta}$  则称  $\phi$  对于  $T$  在  $\partial\Theta_{01}$  上有 **Neyman 结构**。
- **引理3.6:** 设  $\phi$  对于  $T$  在  $\partial\Theta_{01}$  上有 Neyman 结构, 则  $\phi$  对于集  $\partial\Theta_{01}$  相似。若  $T$  还是  $P_{\theta}, \theta \in \partial\Theta_{01}$  (有界) 完全的, 则两者等价。
- **定理3.4:** 对于**定理3.3**中单参数指数分布族, 给定水平  $\alpha$ , 考虑检验  $H_0 : \theta_1 < \theta < \theta_2 \text{ v.s. } H_1 : \theta \leq \theta_1 \text{ or } \theta \geq \theta_2$ 。若检验  $\phi^*$  有形式

$$\phi^*(X) = \begin{cases} 1 & T(X) < k_1 \text{ or } T(X) > k_2 \\ \gamma_i & T(X) = k_i, i = 1, 2 \\ 0 & k_1 < T(X) < k_2 \end{cases}$$

其中  $k_i, \gamma_i$  由  $E_{\theta_1} \phi^*(X) = E_{\theta_2} \phi^*(X) = \alpha$  确定, 则  $\phi^*(X)$  为水平  $\alpha$  的 UMPU 检验。

- **定理3.5:** 对于**定理3.3**中单参数指数分布族, 给定水平  $\alpha$ , 考虑检验  $H_0 : \theta = \theta_0 \text{ v.s. } H_1 : \theta \neq \theta_0$ 。若检验  $\phi^*$  有形式

$$\phi^*(X) = \begin{cases} 1 & T(X) < k_1 \text{ or } T(X) > k_2 \\ \gamma_i & T(X) = k_i, i = 1, 2 \\ 0 & k_1 < T(X) < k_2 \end{cases}$$

其中 $k_i, \gamma_i$ 由 $E_{\theta_0} \phi^*(X) = \alpha, E_{\theta_0} T(X) \phi^*(X) = \alpha E_{\theta_0} T(X)$ 确定, 则 $\phi^*(X)$ 为水平 $\alpha$ 的UMPU检验。

- 对于多参数的检验问题参考P33-P38, 冗余参数的概念。
- **One-sample Problems** (P45-P49)
- **Two-sample Problems** (P50-P56)
- **一致最优不变检验 (UMPI)** (P57-P63)
  - **定义3.7:** 对检验问题 $H_0 : \theta \in \Theta_0$  v.s.  $H_1 : \theta \in \Theta_1$ 和变换群 $G$ 
    - 称检验问题在变换群 $G$ 下是不变的 (invariant), 如果 $g^* \Theta_0 = \Theta_0, g^* \Theta_1 = \Theta_1, \forall g^* \in G^*$
    - 对于在群 $G$ 下不变的检验问题, 一个检验 $\phi$ 称为是不变检验若 $\phi(gX) = \phi(X), \forall g \in G$ 。
    - 若对任水平 $\alpha$ 的不变检验 $\phi$ , 存在水平 $\alpha$ 的不变检验 $\phi^*$ 使得 $\beta_\theta(\theta) < \beta_{\phi^*}(\theta), \forall \theta \in \Theta_1$ , 则称 $\phi^*$ 为水平 $\alpha$ 的一致最优不变检验 (UMPI)。
    - 统计量 $T(X)$ 称为在变换群 $G$ 下为极大不变量若 $T(gX) = T(X), \forall g \in G$ , 且若 $T(X) = T(Y) \Rightarrow$ 存在 $g$ 使得 $gX = Y$ 。
  - 求UMPI检验时, 先找一个适当的极大不变量 $T$  (不一定唯一), 然后找出 $T$ 的分布族, 在此分布族下是否有UMP检验, 若有则为UMPI检验
    - 设统计量 $T(X)$ 为群 $G$ 的极大不变量,  $\phi$ 为不变检验 $\Leftrightarrow$ 存在可测函数 $h$ 使得 $\phi(X) = h(T(X))$ 。
    - 多看作业
    - 使用充分统计量
    - 群 $G$ 在样本空间的变化能否在充分统计量 $T$ 的值域空间诱导出一个变换群 $G^T$  (若不能, 则 $T$ 无用)
    - 转化到 $T$ 后在群 $G^T$ 下施以不变性要求, 对此再利用前面说的方法求UMPI检验。
- **假设检验与Wald决策理论** (P64-P68)
  - 设 $a_0$ 表示接受,  $a_1$ 表示拒绝, 设损失函数为 $L(a, \theta), \theta \in \Theta$ , 则对任一随机化决策函数 $\phi(X)$ , 其风险为

$$R_\theta(\phi) = E_\theta[L(a - 0, \theta)(1 - \phi(X)) + L(a_1, \theta)\phi(X)]$$

问题归结于找 $\phi$ 使 $R_\theta(\phi)$ 最小。

- **基于似然的检验**

- **定义3.8:** 统计量

$$\Lambda(X) = \frac{\sup_{\theta \in \Theta_0} f(X, \theta)}{\sup_{\theta \in \Theta} f(X, \theta)} = \frac{\sup_{\theta \in \Theta_0} L(X, \theta)}{\sup_{\theta \in \Theta} L(X, \theta)}$$

称为似然比统计量, 若  $\Lambda < c$  拒绝  $H_0$ 。

- 给定水平  $\alpha$ , 若存在  $c_\alpha$  使得  $\sup_{\theta \in \Theta_0} P_\theta(\Lambda(X) < c_\alpha) = \alpha$ , 则LRT为水平  $\alpha$  的检验。
- **定理3.7:** 设  $X_1, X_2, \dots, X_n$  i.i.d  $\sim f(x, \theta), \theta \in \Theta$ , 满足定理2.6中条件  $B1 - B6$  且  $I(\theta) = J(\theta), \forall \theta \in \Theta$ 。若MLE  $\hat{\theta}_n$  满足  $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d.f.} N(0, [I(\theta)]^{-1})$ 。考察检验问题  $H_0 : \theta \in \Theta_0 = \{\theta \in \Theta \mid g(\theta) = 0\}$  v.s.  $H_1 : \Theta / \Theta_0$ , 这里  $g : R^p \rightarrow R^r (r < p)$  为连续可微函数,  $g = (g_1, g_2, \dots, g_r)^T, \text{rank} \frac{\partial g(\theta)}{\partial \theta^T} = r$ 。则在  $H_0$  下, LRT统计量  $\Lambda_n(X)$  有

$$-2 \log \Lambda_n(X) \xrightarrow{d.f.} \chi_r^2$$

此检验拒绝域为  $-2 \log \Lambda_n(X) > \chi_r^2(\alpha)$ , 渐近有  $\alpha$  水平。

- **截断型分布的似然比** (P76)
- **Bartlett Correction** (P77)
- **Wald test**

$$\blacksquare \quad W_n = n[g(\hat{\theta}_n)]^T \left\{ \frac{\partial g(\hat{\theta}_n)}{\partial \theta^T} [I(\hat{\theta}_n)]^{-1} \left[ \frac{\partial g(\hat{\theta}_n)}{\partial \theta^T} \right]^T \right\}^{-1} g(\hat{\theta}_n) > c$$

此处  $\hat{\theta}_n$  为MLE。

- **Score test**

$$\blacksquare \quad R_n = \left[ S(\hat{\theta}_{n0}) \right]^T \left[ nI(\hat{\theta}_{n0}) \right]^{-1} S(\hat{\theta}_{n0}) > c$$

其中  $\hat{\theta}_{n0}$  为在约束  $H_0$  下的MLE,  $S(\theta) = \frac{\partial l(\theta)}{\partial \theta}$  为score function。

- 在  $H_0$  下,  $W_n \xrightarrow{d.f.} \chi_r^2$ , 故当  $W_n > \chi_r^2(\alpha)$  时拒绝  $H_0$ , 此检验渐近地有  $\alpha$  水平。
- 在  $H_0$  下,  $R_n \xrightarrow{d.f.} \chi_r^2$ , 故当  $R_n > \chi_r^2(\alpha)$  时拒绝  $H_0$ , 此检验渐近地有  $\alpha$  水平。
  - $W_n, R_n$  的定义中  $nI(\theta)$  用基于  $n$  个样本的Fisher信息阵  $I_n(\theta)$  代替。
  - 三个检验是渐近等价的。

- **定义3.9:** p-value为在观测样本  $X$  下, 零假设被拒绝的最小显著性水平。p-value也称为observed significance level。



- **定义3.10:**  $p(X) = \inf\{\alpha \mid \phi_\alpha(X) = 1\}$ 称为 (样本 $X$ ) 的p-value。
- **拟合优度检验**

- **Pearson:**

$$T_n = \sum_{j=1}^k \frac{(\xi_{nj} - np_j)^2}{np_j} \xrightarrow{d.f.} \chi_{k-1}^2$$

- 由具体数据可以计算出 $T_n$ 的值, 记为 $t$ , 从而可以计算 $p(t) = P(\chi_{k-1}^2 > t)$ , 即为检验的 $p$ 值。
- 对于有限多个点的分布族 $F_\theta$ , 需要先利用 $X_1, \dots, X_n$ 对 $\theta$ 做估计 $\hat{\theta}_n$  (通常是极大似然估计MLE), 然后计算

$$T_n = \sum_{j=1}^k \frac{(\xi_{nj} - np_j(\hat{\theta}_n))^2}{np_j(\hat{\theta}_n)} \xrightarrow{d.f.} \chi_{k-r-1}^2$$

- **列联表检验**

- $$T_n = \sum_{i=1}^r \sum_{j=1}^s \frac{(nX_{ij} - m_i n_j)^2}{nm_i n_j}$$

- 当 $n$ 充分大时, 在原假设 $H_0$ 下 $T_n \xrightarrow{d.f.} \chi_{(r-1)(s-1)}^2$ 。

- **基于经验分布的拟合优度检验**

- Glivenko-Cantelli定理:

$$\sup_x \left| \hat{F}_n(x) - F(x) \right| \rightarrow 0 \quad \text{a.s.}$$

- $D_n, V_n, C_n, A_n$  等定义及性质P109-P117。

- **正态性检验**

- Q-Q plot (P120)
- Shapiro-Wilk Test (P124)

- **非参数检验**

- 符号检验
- 基本思路: 设 $X_1, X_2, \dots, X_n$  i.i.d.  $\sim F(x)$  (未知), 固定 $u$ ,  $p = F(u) = P(X_i \leq u)$ , 考虑如下的检验问题 (其中 $p_0 \in (0, 1)$ 已知)

- $H_0 : p \leq p_0 \leftrightarrow H_1 : p > p_0;$

- $H_0 : p = p_0 \leftrightarrow H_1 : p \neq p_0.$

令

$$\Delta_i = \begin{cases} 1, & X_i - u \leq 0 \\ 0, & \text{otherwise} \end{cases}$$

则 $\Delta_i \text{i.i.d} \sim \text{Bernoulli}(p)$ ，然后急于之前的UMP检验以及UMPU检验进行检验。

- 置换检验 (Permutation Tests) P131
- 秩检验 P150

## 第四章

- 置信区间：称区间 $[L(X), U(X)]$ 为 $\theta$ 的 $100(1 - \alpha)\%$ 置信区间，若 $P_\theta(L(X) \leq \theta \leq U(X)) \geq 1 - \alpha, \forall \theta \in \Theta$ 。
- 给定样本 $X$ ，区间 $[L(X), U(X)]$ 在样本重复下，有 $100(1 - \alpha)\%$ 的这样的区间将会含有真值。

## 第五章

- **Jeffreys先验**： $\pi(\theta) \propto |I(\theta)|^{\frac{1}{2}}$
- **定义5.1**：设 $A$ 为决策问题的行动空间， $L(a, \theta) \geq 0$ 为损失函数， $\theta$ 先验分布为 $\Pi(\theta)$ ，若决策函数 $\delta(x)$ 满足 $\forall x, E[L(\delta(x), \theta) | X = x] = \min_{a \in A} E[L(a, \theta) | X = x]$ ，则称 $\delta(x)$ 为**Bayes决策**，记为 $\delta_B(x)$ 。
- **定义5.2**：估计 $\hat{\theta}_M$ 称为 $\theta$ （相对于损失函数 $L$ ）的极小极大估计，若对任何估计 $\hat{\theta}, \sup_{\theta \in \Theta} R_\theta(\hat{\theta}) \geq \sup_{\theta \in \Theta} R_\theta(\hat{\theta}_M)$
- 经验Bayes P35
- Bayes检验 P42